

Classificação de Patologias Biliares via CPRE

Vicente Martins¹, Diogo Rodrigues¹, Rui Gonçalves¹, and Gabriel Antunes¹

Departamento de Informática, Universidade do Minho, Braga, Portugal
{pg58812,pg60244,pg59847,pg60259}@alunos.uminho.pt

Abstract. Este trabalho explora a utilização de técnicas de Deep Learning para a classificação automática de imagens médicas de Colangiopancreatografia Retrógrada Endoscópica (CPRE). Foram avaliadas diferentes arquiteturas pré-treinadas, incluindo ResNet50, DenseNet121, MobileNetV2, EfficientNet e DeiT III, recorrendo a transfer learning e fine-tuning. O dataset foi sujeito a pré-processamento, data augmentation e balanceamento das classes de treino. Os modelos foram avaliados através de métricas como Accuracy, Recall, Precision e F1-score macro.

Keywords: Deep Learning · Medical Image Classification · Transfer Learning · CPRE.

1 Introdução

A classificação automática de imagens médicas tem vindo a ganhar relevância devido ao potencial das técnicas de Deep Learning no apoio ao diagnóstico clínico. Neste contexto, este trabalho tem como objetivo a classificação de imagens obtidas por Colangiopancreatografia Retrógrada Endoscópica (CPRE) em quatro classes distintas: Biliary Leaks, Lithiasis, Normal e Stricture. Adicionalmente, procurou-se ultrapassar a baseline previamente estabelecida de F1-score macro de 0.738.

Como ponto de partida para o desenvolvimento do projeto, foi utilizada uma implementação previamente desenvolvida no âmbito do mesmo tema, disponibilizada como referência e sugerida pelo docente da unidade curricular. A partir dessa base inicial foram realizadas diversas adaptações e melhorias, incluindo a reformulação do pipeline de processamento de dados, aplicação de técnicas de data augmentation, utilização de transfer learning e avaliação de diferentes arquiteturas de Deep Learning.

Ao longo do projeto foram estudados e comparados vários modelos, nomeadamente ResNet50, EfficientNet, DeiT III, entre outros com o objetivo de procurar identificar a solução com melhor capacidade de generalização para o conjunto de imagens médicas disponibilizado.

O trabalho inclui ainda a análise dos resultados obtidos através de métricas de classificação, bem como a exploração de técnicas de interpretabilidade que permitam compreender o processo de decisão dos modelos desenvolvidos.

2 Dataset e Pré-processamento dos Dados

O dataset utilizado neste trabalho é constituído por imagens médicas obtidas através de Colangiopancreatografia Retrógrada Endoscópica (CPRE), distribuídas por quatro classes clínicas distintas: *Biliary Leaks*, *Lithiasis*, *Normal* e *Stricture*.

Numa fase inicial foi realizada uma análise da distribuição das imagens por classe, verificando-se a existência de diferenças significativas no número de exemplos disponíveis para cada categoria. Esta situação poderia introduzir enviesamento durante o processo de treino, favorecendo as classes com maior representação.




Fig. 1. Dados não Balanceados.

Com o objetivo de minimizar este problema, foram aplicadas técnicas de *data augmentation* às classes menos representadas, permitindo aumentar artificialmente o número de amostras disponíveis e obter um conjunto de treino mais equilibrado. Entre as técnicas utilizadas destacam-se pequenas rotações, alterações de contraste, operações de zoom e adição de ruído.

O balanceamento do conjunto de treino foi realizado de forma a garantir que todas as classes apresentassem aproximadamente o mesmo número de exemplos. Esta abordagem permite reduzir o enviesamento do modelo para as classes mais representadas, promovendo uma aprendizagem mais equilibrada e melhorando a capacidade de generalização para todas as categorias clínicas.

Adicionalmente, foi efetuado um pré-processamento das imagens com o objetivo de remover regiões sem informação relevante, nomeadamente barras pretas presentes nas margens de algumas imagens.




Fig. 2. Dados Balanceados.

Com a análise das imagens, reparou-se que algumas apresentavam as imagens com os valores invertidos, ou seja, características pretas eram apresentadas com brancas e vice-versa.

Criou-se um modelo MLP para detetar automaticamente as imagens invertidas. Este foi treinado usando as imagens encontradas no dataset completo, removendo as imagens encontradas no teste e de validação. Uma precaução tomada foi a remoção dos cantos das imagens, já que a maior parte das imagens tem cantos pretos, exceto as imagens invertidas. Ou seja, se os cantos existissem o modelo aprendia a olhar para os cantos em vez de aprender a reconhecer os detalhes invertidos.

O MLP utilizou 2676 imagens do dataset completo, sendo cada imagem duplicada para ambas as versões, invertida e normal, totalizando 5352. Realizou-se uma divisão 80/20 para treino e validação, utilizando a secção de teste do dataset préprocessado como teste. Na validação e treino atingiu 99.7% de *accuracy*, tendo classificado corretamente todas as imagens no teste.

3 Modelos Utilizados

Com o objetivo de identificar a arquitetura mais adequada para a classificação das imagens CPRE, foram avaliados diferentes modelos de Deep Learning basea-

dos em redes neurais convolucionais e arquiteturas Transformer. Todos os modelos foram utilizados através da abordagem de *transfer learning*, recorrendo a pesos pré-treinados no ImageNet e adaptando a camada final de classificação para as quatro classes do problema.

Os modelos avaliados foram os seguintes:

- **ResNet50** – arquitetura baseada em ligações residuais (*residual connections*), amplamente utilizada em tarefas de classificação de imagem devido à sua capacidade de treinar redes profundas de forma eficiente.
- **MobileNetV2** – modelo otimizado para eficiência computacional, apresentando um reduzido número de parâmetros e menor custo computacional.
- **EfficientNet (B0, B4 e B7)** – família de modelos que procura um equilíbrio entre profundidade, largura e resolução da imagem, permitindo comparar diferentes níveis de complexidade da arquitetura.
- **DenseNet121** – arquitetura baseada em ligações densas entre camadas, favorecendo a reutilização de características e reduzindo problemas associados ao desaparecimento do gradiente.
- **DeiT III (Data-efficient Image Transformer)** – modelo baseado em Vision Transformers, desenvolvido para obter um elevado desempenho mesmo com quantidades moderadas de dados de treino.
- **Swin Transformer** – arquitetura Transformer hierárquica baseada em janelas locais de atenção, amplamente utilizada em tarefas de visão computacional e imagem médica.
- **ConvNeXt V2** – arquitetura moderna inspirada nas CNNs clássicas, incorporando conceitos recentes que lhe permitem competir com modelos Transformer em tarefas de classificação de imagem.

A comparação entre estas arquiteturas permitiu avaliar diferentes abordagens para o problema, analisando o impacto da complexidade do modelo, capacidade de generalização e desempenho obtido no conjunto de teste.

4 Transfer Learning e Fine-Tuning

Uma vez que o dataset disponível possui uma dimensão relativamente reduzida para o treino de modelos de Deep Learning a partir do zero, foi adotada a abordagem de *transfer learning*. Esta técnica consiste na utilização de modelos previamente treinados em grandes conjuntos de dados, permitindo aproveitar características visuais já aprendidas durante o processo de treino original.

Todos os modelos considerados neste trabalho foram inicializados com pesos pré-treinados no ImageNet e posteriormente adaptados ao problema de classificação das imagens CPRE. Para tal, as camadas finais de classificação foram substituídas por novas camadas totalmente ligadas (*fully connected layers*) com quatro neurónios de saída, correspondentes às quatro classes do dataset.

Durante o desenvolvimento foram realizados diversos testes de *fine-tuning*, explorando diferentes configurações de treino. Foram avaliadas duas funções de

perda distintas: *Cross Entropy Loss*, utilizada como abordagem base para classificação multiclasse, e *Focal Loss*, com o objetivo de dar maior importância aos exemplos mais difíceis durante o treino.

Foram também comparados diferentes algoritmos de otimização, nomeadamente Adam e AdamW. Adicionalmente, foram efetuadas experiências com diferentes taxas de aprendizagem (*learning rate*), verificando-se que valores mais reduzidos permitiram obter melhores resultados nos modelos DenseNet121 e DeiT III, particularmente no conjunto de teste.

Foi ainda testada a estratégia de congelamento parcial das camadas (*layer freezing*), procurando preservar as características aprendidas durante o pré-treino. No entanto, os resultados obtidos não apresentaram melhorias significativas relativamente ao treino completo dos modelos, pelo que essa abordagem não foi adotada na configuração final.

O conjunto destas experiências permitiu identificar as configurações mais adequadas para cada arquitetura, contribuindo para a melhoria do desempenho e capacidade de generalização dos modelos avaliados.

5 Resultados

Nesta secção são apresentados os resultados obtidos pelos diferentes modelos avaliados ao longo do projeto. Inicialmente é analisada a evolução do processo de treino através das curvas de aprendizagem, permitindo observar o comportamento das métricas ao longo das épocas. Posteriormente são apresentados os resultados obtidos nos conjuntos de validação e teste, possibilitando a comparação direta entre as diferentes arquiteturas estudadas.

Por fim, são analisadas as matrizes de confusão e os métodos de interpretabilidade aplicados aos modelos, permitindo compreender melhor o processo de decisão das redes neuronais e identificar as regiões das imagens que mais influenciaram as classificações efetuadas.

5.1 Evolução do Treino

Durante o treino foram monitorizadas diversas métricas de desempenho, nomeadamente a função de perda, accuracy, F1-score e AUC. A análise destas curvas permitiu acompanhar a evolução da aprendizagem dos modelos e identificar possíveis fenómenos de sobreajuste (*overfitting*) ou subajuste (*underfitting*).

As Figuras seguintes apresentam a evolução das métricas para os diferentes modelos considerados neste trabalho.




Fig. 3. DeitIII Gráfico

A análise das curvas de aprendizagem revela a existência de fenômenos de sobreajuste (*overfitting*) em vários dos modelos avaliados. Verifica-se que as métricas do conjunto de treino continuam a melhorar ao longo das épocas, atingindo valores próximos de 100% de accuracy e F1-score, enquanto o desempenho no conjunto de validação estabiliza ou apresenta oscilações significativas.

Este comportamento é também observado através da evolução da função de perda, onde a *training loss* diminui continuamente, ao passo que a *validation loss* tende a aumentar após as primeiras épocas de treino.

Apesar da presença de overfitting, o principal objetivo desta fase do trabalho consistiu na comparação do desempenho relativo entre diferentes arquiteturas de Deep Learning. Assim, foi dada prioridade à avaliação de múltiplos modelos e configurações, em detrimento de uma otimização exaustiva das técnicas de regularização. Ainda assim, foram efetuadas experiências com diferentes taxas de aprendizagem, funções de perda, algoritmos de otimização e estratégias de transferência de aprendizagem, procurando melhorar a capacidade de generalização dos modelos.




Fig. 4. ConvNext Gráfico

5.2 Resultados de Validação

Nesta secção são apresentados os valores de F1-score obtidos no conjunto de treino e no conjunto de validação para os diferentes modelos avaliados. Esta comparação permite analisar a capacidade de generalização de cada arquitetura e identificar possíveis diferenças entre o desempenho durante o treino e a validação.

Modelo	Train F1-score	Val F1-score
ResNet50	0.75	0.5515
MobileNetV2	0.7159	0.5861
EfficientNet-B4	0.8668	0.4946
EfficientNet-B7	0.9684	0.5819
DenseNet121	0.8534	0.4931
DeiT III	0.9816	0.5613
Swin Transformer	0.9912	0.6044
ConvNeXt V2	0.9904	0.5667

Table 1. Resultados de F1-score nos conjuntos de treino e validação.

A análise dos resultados de validação permite observar diferenças significativas entre o desempenho obtido no conjunto de treino e no conjunto de validação.

Em praticamente todos os modelos verifica-se que o F1-score de treino é substancialmente superior ao F1-score de validação, indicando a presença de fenômenos de sobreajuste (*overfitting*).

Os resultados obtidos evidenciam que o aumento da complexidade do modelo não conduz necessariamente a um melhor desempenho em validação. Este comportamento poderá estar relacionado com a dimensão relativamente reduzida do dataset disponível e com a dificuldade inerente à classificação das diferentes patologias presentes nas imagens CPRE.

5.3 Resultados de Teste

Modelo	Accuracy	Precision Macro	Recall Macro	F1 Macro
DeiT III	0.7266	0.6965	0.6913	0.6782
ConvNeXt V2	0.7266	0.6594	0.6744	0.6516
Swin Transformer	0.6854	0.7040	0.5816	0.6179
ResNet50	0.6105	0.5735	0.6049	0.5841
EfficientNet-B7	0.6779	0.7576	0.5516	0.5359
MobileNetV2	0.5581	0.5402	0.4747	0.4640
EfficientNet-B0	0.4682	0.4217	0.4342	0.4078
DenseNet121	0.1948	0.5853	0.3599	0.2095

Table 2. Resultados obtidos no conjunto de teste.

Os resultados obtidos no conjunto de teste demonstram que o modelo DeiT III apresentou o melhor desempenho global, alcançando uma accuracy de 72.66% e um F1-score macro de 0.6782. O ConvNeXt V2 obteve resultados muito próximos, apresentando a mesma accuracy mas um F1-score ligeiramente inferior.

Os modelos baseados em Transformers revelaram, de forma geral, melhor capacidade de generalização relativamente às arquiteturas convolucionais tradicionais. O Swin Transformer apresentou igualmente um desempenho competitivo, alcançando um F1-score macro de 0.6179.

Entre os modelos CNN, o ResNet50 e o EfficientNet-B7 obtiveram os melhores resultados, enquanto o MobileNetV2 e o EfficientNet-B0 apresentaram desempenhos mais modestos. O DenseNet121 revelou dificuldades significativas na generalização para o conjunto de teste, obtendo o pior resultado entre os modelos avaliados.

De forma global, os resultados sugerem que as arquiteturas Transformer foram as mais adequadas para o problema de classificação das imagens CPRE considerado neste trabalho.

5.4 Análise das Matrizes de Confusão




Fig. 5. Matrizes de confusão dos modelos ConvNeXt V2 e DeiT III.

Na Figura 5 são apresentadas as matrizes de confusão dos dois modelos com melhor desempenho no conjunto de teste. A matriz superior corresponde ao modelo ConvNeXt V2, enquanto a matriz inferior corresponde ao modelo DeiT III.

Observa-se que ambos os modelos apresentam um bom desempenho na identificação das classes *Lithiasis* e *Stricture*, concentrando a maioria das previsões corretas na diagonal principal da matriz. Por outro lado, a classe *Biliary Leaks*

revelou ser a mais difícil de distinguir, sendo frequentemente confundida com a classe *Normal*. Verifica-se igualmente a existência de algumas confusões entre as classes *Lithiasis* e *Normal*, bem como entre *Stricture* e *Lithiasis*.

Comparando os dois modelos, o DeiT III apresenta uma distribuição mais equilibrada dos erros de classificação e um número ligeiramente superior de previsões corretas para as classes mais representadas do conjunto de teste, o que contribuiu para o melhor desempenho global observado nas métricas de avaliação.

5.5 Interpretabilidade dos Modelos




Fig. 6. ConvNext Occlusion




Fig. 7. DeiTIII Occlusion

Para além da avaliação quantitativa do desempenho, foi realizada uma análise de interpretabilidade com recurso à técnica de *Occlusion Sensitivity*. Esta abordagem permite identificar as regiões da imagem que mais influenciam a decisão do modelo, ocultando progressivamente pequenas áreas da imagem e avaliando o impacto na probabilidade da classe prevista.

As Figuras 6 e 7 apresentam os mapas de sensibilidade obtidos para os modelos ConvNeXt V2 e DeiT III, respetivamente. A utilização de técnicas de interpretabilidade constitui uma ferramenta importante no contexto da análise de imagens médicas, permitindo aumentar a transparência do processo de decisão

dos modelos e fornecer evidências visuais que auxiliam a validação clínica dos resultados.

6 Trabalho futuro

Apesar dos resultados obtidos, existem várias oportunidades para melhorar o desempenho dos modelos desenvolvidos.

Uma das principais linhas de trabalho futuro passa pela exploração de técnicas adicionais de pré-processamento e aumento de dados, bem como pela otimização mais aprofundada dos hiperparâmetros de treino, incluindo estratégias de regularização para reduzir os fenômenos de sobreajuste observados durante algumas experiências.

Pretende-se igualmente continuar a investigação de arquiteturas Transformer e modelos híbridos que combinem características de redes convolucionais e Transformers, procurando aumentar a capacidade de generalização do sistema.

Outra direção de trabalho consiste na aplicação de métodos avançados de interpretabilidade, como Grad-CAM e Attention Maps, permitindo uma compreensão mais detalhada do processo de decisão dos modelos.

Por fim durante o desenvolvimento do projeto foi também iniciada a implementação de modelos baseados em Autoencoders, com o objetivo de explorar tarefas de representação latente, deteção de anomalias e aprendizagem não supervisionada. No entanto, devido às limitações temporais do projeto, esta componente não foi concluída, constituindo uma linha de investigação promissora para trabalhos futuros.

7 Conclusão

Neste trabalho foram exploradas diferentes arquiteturas de Deep Learning para a classificação automática de imagens CPRE em quatro categorias clínicas distintas. Foram avaliados modelos baseados em redes convolucionais e Transformers, recorrendo a técnicas de *transfer learning* e *fine-tuning*.

Os melhores resultados foram obtidos pelos modelos DeiT III e ConvNeXt V2, que demonstraram melhor capacidade de generalização relativamente às restantes arquiteturas avaliadas. Adicionalmente, a utilização de matrizes de confusão e mapas de sensibilidade permitiu analisar o comportamento dos modelos e interpretar as suas decisões.

Apesar dos resultados obtidos, não foi possível superar o modelo de referência disponibilizado inicialmente, que apresentava um F1-score superior ao melhor resultado alcançado neste trabalho. Ainda assim, o projeto permitiu comparar diferentes arquiteturas, identificar as suas limitações e adquirir experiência na aplicação de técnicas modernas de Deep Learning a imagens médicas.

Os resultados obtidos demonstram que a classificação automática de imagens CPRE continua a ser um problema desafiante, existindo ainda margem para melhorias futuras ao nível dos dados, das arquiteturas utilizadas e das estratégias de treino.